## Homework4 Report Problem Set

Professor Pei-Yuan Wu EE5184 - Machine Learning

姓名:楊宗賢 學號: B06901031

1. (0.5%) 請說明你實作之 RNN 模型架構及使用的 word embedding 方法,回報模型的正確率並繪出訓練曲線。(0.5%) 請實作 BOW+DNN 模型,敘述你的模型架構,回報正確率並繪出訓練曲線。

我訓練了三個 RNN model, 命名為 model\_2、model\_3、model\_4, 細節如下:

我的家」—個KNN moder,中有為 moder_2、moder_3、moder_4,細的如下。				
model_2	model_3	model_4		
word embedding: Word2Vec, skip-gram, size=250				
iter: 6	iter: 7	iter: 7		
max_final_vocab: 37000	max_final_vocab: 35000	max_final_vocab: 35000		
Padding: post, maxlen=60				
RNN structure:				
LSTM: 5				
Dropout: 0.1				
Dense: 400				
Dense: 100				
Dense: 40				
Dense: 2				
訓練方式: 15 epochs, batch size:100				
	正確率			
training: 0.7571 training: 0.7625		training: 0.7622		
validation: 0.7605 validation: 0.7660		validation: 0.7642		
Kaggle private: 0.74652	Kaggle private: 0.74957	Kaggle private: 0.75297		
0.7650 0.7625 0.7600 0.7575 0.7550 0.7525 0.7500 0.7475	0.770 0.765 0.760 0.755 0.750 0.740 0.740 0.740 0.740 0.740 0.740 0.740 0.740	0.7650 0.7625 0.7600 0.7575 0.7550 0.7550 0.7500		

三個 RNN model 合取 ensemble 後, Kaggle private score=0.75472。

## BOW+DNN 細節如下:

o bag size = 8000, using hash(word)%[bag size] to classify

0.745

0.740

0.735

Dense: 2000Dropout: 0.3Dense: 200

Dense: 20Dense: 2

∘ 20 epochs, batch size:100



training acc: 0.9880validation acc: 0.7313

• Kaggle private score: 0.47047

2. (1%) 請敘述你如何 improve performance(preprocess, embedding, 架構等), 並解釋為何這些做法可以使模型進步。

我

3. (1%) 請比較不做斷詞 (e.g., 以字為單位) 與有做斷詞,兩種方法實作出來的效果 差異,並解釋為何有此差別。

4. (1%) 請比較 RNN 與 BOW 兩種不同 model 對於"在說別人白痴之前,先想想自己"與"在說別人之前先想想自己,白痴"這兩句話的分數(model output),並討論造成差異的原因。

白痴之前,		,白痴
RNN	0.53428876 0.4657113	0.47743967 0.5225603
BOW	9.9965107e-01 3.4895807e-04	9.9965107e-01 3.4895807e-04

兩句話由完全相同的詞所組成,但詞出現的順序不同。RNN將前句判為普通內容、而後句則判為惡意內容;BOW給予兩句話完全相同的分數,皆判為普通內容。

通常**白痴**二字接續在逗號後面,在中文裡較有可能帶有貶損的意涵,然而 BOW 無法分辨詞出現順序的差異。因此 RNN 能區分兩者、而 BOW 不能。

5. (1%)

6. (1%)